

大模型多模态期末试卷

满分 150 分 考试时间 150 分钟

注意事项：

- 本试卷共 三大题，包括选择题、填空题、解答题，共 **24** 小题。
- 请将答案写在答题区指定位置；解答题须写出必要的文字说明、推导过程或演算步骤。
- 涉及数学公式推导时，请清晰写出关键中间步骤；只写最终结果不得分。
- 本试卷中如无特殊说明，图像分辨率为 $H \times W$ ，patch 大小为 P ，视觉 token 数为 N_v ，文本序列长度为 L ，隐藏维度为 d ，对比学习温度系数为 τ ，扩散步数为 T ，批大小为 B 。

一、选择题（本大题共 12 小题，每小题 5 分，共 60 分。在每小题给出的四个选项中，只有一项是符合题目要求的。）

- 关于 CLIP（Contrastive Language-Image Pre-training）的核心训练机制，下列说法**正确**的是
(A) CLIP 采用单塔编码器，将图像与文本拼接后做自注意力融合
(B) CLIP 使用双塔结构分别编码图像与文本，通过批内对比学习（InfoNCE）拉近匹配图文对、推远不匹配对
(C) CLIP 的训练目标是最小化图像与文本在像素空间的均方误差（MSE）
(D) CLIP 只能处理固定 224×224 图像，无法泛化到其他分辨率
- 设 Vision Transformer（ViT）输入图像分辨率为 224×224 ，patch 大小为 16×16 ，并额外添加 1 个 CLS token。则送入 Transformer 编码器的序列长度为
(A) 14 (B) 196
(C) 197 (D) 225
- 在 Whisper 音频编码器中，原始音频采样率 16 kHz，使用 STFT 提取 Log-Mel 梅尔频谱，帧移 Hop Size = 160 个采样点；得到梅尔频谱特征序列后，经过两层步长 Stride=2 的一维卷积降采样，送入 Transformer。若一段音频总长 12 秒，求最终输入 Transformer 的 Token 序列长度 L ：
(A) 1200 (B) 600
(C) 300 (D) 150
- Stable Diffusion 属于 Latent Diffusion Model (LDM)，其核心设计是
(A) 直接在原始像素空间 $x \in \mathbb{R}^{H \times W \times 3}$ 上进行 T 步去噪
(B) 先用 VAE 将图像压缩到低维隐空间 z ，再在隐空间训练扩散去噪网络，大幅降低计算量
(C) 完全放弃 VAE，仅使用 GAN 判别器指导扩散过程
(D) 只在文本嵌入空间做扩散，不生成任何图像

5. 关于 Early Fusion、Late Fusion 与 Intermediate Fusion（交叉注意力融合），下列判断**错误**的是
- (A) Early Fusion 在输入层即将多模态特征拼接或相加，计算简单但模态异质性处理困难
 - (B) Late Fusion 各模态独立编码后在决策层融合，模块化强但难以捕获细粒度跨模态交互
 - (C) Intermediate Fusion 通过 Cross-Attention 让一种模态的 Query 查询另一种模态的 Key/Value，是 LLaVA、Flamingo 等的主流方案
 - (D) Late Fusion 一定优于 Intermediate Fusion，因为避免了跨模态注意力带来的 $O(N_v^2)$ 计算开销
6. 下列多模态大模型架构与其核心连接器（Connector）的匹配，**正确**的是
- (A) LLaVA —Q-Former；BLIP-2 —线性投影层；Flamingo —Perceiver Resampler
 - (B) LLaVA —线性/MLP 投影层；BLIP-2 —Q-Former；Flamingo —门控交叉注意力层（Gated Cross-Attention）
 - (C) 三者均采用 Q-Former 作为唯一连接器
 - (D) LLaVA —扩散 U-Net；BLIP-2 —VAE 编码器；Flamingo —CLIP 文本塔
7. 关于 DDPM 前向加噪过程 $q(x_t|x_{t-1}) = \mathcal{N}(\sqrt{1-\beta_t}x_{t-1}, \beta_t I)$ ，下列说法**正确**的是
- (A) 前向过程是非马尔可夫的，当前状态依赖全部历史步
 - (B) 当 $t \rightarrow T$ 且 $\bar{\alpha}_t = \prod_{s=1}^t (1 - \beta_s) \rightarrow 0$ 时， x_T 近似服从标准高斯分布
 - (C) 反向去噪过程 $q(x_{t-1}|x_t)$ 有解析闭式解，可直接采样
 - (D) 方差调度 β_t 必须恒定为常数，否则训练不稳定
8. 关于 VQ-VAE / VQ-GAN 中离散视觉 Token 化的机制，下列说法**正确**的是
- (A) Codebook 中每个向量通过 argmax 操作被选中，梯度可通过 Straight-Through Estimator 近似回传
 - (B) 离散化后图像无法用 Transformer 建模，必须退回 CNN
 - (C) VQ 损失仅包含重建损失，不含 codebook 与 commitment 项
 - (D) Codebook 大小对生成质量无影响，越大越好且无需担心码本利用率
9. 关于 Flux 文生图模型的底层技术与特性，下列说法**错误**的是（ ）
- (A) Flux 基于 Flow Matching 流匹配范式训练，而非传统 DDPM 扩散损失
 - (B) Flux 主干网络采用 DiT（Diffusion Transformer），抛弃了 Stable Diffusion 经典 U-Net 结构
 - (C) Flux 原生对图像内文字、人体手部细节生成效果显著优于 SDXL
 - (D) Flux 基础版本显存占用低于 SDXL，8G 显存显卡可无压力本地运行
10. 关于多模态大模型三个核心问题——表示(Representation)、对齐(Alignment)与融合(Fusion)，下列说法**正确**的是
- (A) 表示关注如何将不同模态映射到统一语义空间；对齐关注跨模态语义对应关系；融合关注多模态信息在下游任务中的联合利用
 - (B) 表示、对齐、融合三者完全等价，只是不同论文的命名差异
 - (C) 融合仅发生在预训练阶段，推理时不再需要跨模态交互
 - (D) 对齐问题仅存在于图文检索任务，在 VQA 等生成任务中不存在

11. 文生图领域存在过多种经典底层生成范式: GAN、VAE、离散自回归 Transformer、扩散 Diffusion 模型。下列关于这些架构的描述, **错误**的是

- (A) GAN 类文生图 (AttnGAN、StackGAN) 依靠生成器与判别器对抗训练, 单步直接输出图像, 无迭代去噪流程; 核心痛点是训练易模式崩溃、高分辨率细节生成能力弱
- (B) VAE 类文生图 (早期 DALL-E 1) 基于潜空间概率建模, 通过编码器压缩图像、解码器依据文本重建画面; 天然存在生成图像偏模糊、纹理表现力不足的缺陷
- (C) 离散自回归 Transformer 文生图 (Parti、Muse) 将图像映射为 VQ-VAE 离散码本, 像文本一样逐 Token 串行预测生成; 不依赖扩散前向加噪、反向去噪流程
- (D) 主流扩散文生图模型里, SD 1.5/XL 的 U-Net 主干、SD3 与 FLUX 的 MMDiT 主干, 采用 AdaLN-Zero 完成文本条件的特征调制

12. 在 CLIP 批内对比学习中, 设 batch 大小为 B , 图像嵌入为 $\{\mathbf{I}_i\}_{i=1}^B$, 文本嵌入为 $\{\mathbf{T}_i\}_{i=1}^B$ (均已 L2 归一化), 相似度 logits 为 $s_{ij} = \mathbf{I}_i^\top \mathbf{T}_j / \tau$ 。下列说法**正确**的是

- (A) 温度 τ 越小, softmax 分布越平滑, 负样本梯度越弱
- (B) 对角线元素 s_{ii} 为正样本对, 非对角线 $s_{ij} (i \neq j)$ 在图像到文本方向充当 in-batch 负样本; τ 越小分布越尖锐, 对困难负样本的区分力越强
- (C) 对比矩阵只需计算上三角, 因为 $s_{ij} = s_{ji}$ 恒成立
- (D) $B = 1$ 时 InfoNCE 仍能有效训练, 因为预训练数据足够大

二、填空题 (本大题共 6 小题, 每小题 5 分, 共 30 分。把答案填在题中横线上。)

13. BLIP 的 Image-grounded Text Decoder 在训练时, 除了对文本部分施加因果掩码 (causal mask) 外, 还允许每个文本 token 关注所有图像 token。设图像 token 数量为 M , 文本长度为 L , 则整个注意力矩阵中**未被掩码**的元素个数为 _____。

14. 在 DDIM 中, 设噪声调度满足 $\alpha_t = 1 - 0.01t$ ($t = 0, 1, \dots, 100$), 且取 $\sigma_t = 0$ 。已知第 50 步的状态 x_{50} 和模型预测的噪声 ϵ , 则计算 x_{49} 时, x_{50} 前面的系数为 _____。

15. 在 CLIP 中, 设 batch 大小为 B , 则参与 InfoNCE 损失计算的**负样本对数**为 _____。

16. 设视觉 token 数 $N_v = 576$, 隐藏维度 $d = 1024$, 注意力头数 $h = 16$ 。单层视觉自注意力中, $QK^\top$ 矩阵的显存占用 (fp16, 每元素 2 字节) 约为 _____ MB (保留整数)。

17. DDPM 前向过程定义 $\alpha_t = 1 - \beta_t$, $\bar{\alpha}_t = \prod_{s=1}^t \alpha_s$ 。则 $q(x_t|x_0)$ 的闭式分布为 _____。

18. 传统双线性、双三次插值重采样作用于像素空间; 而多模态大模型中的视觉重采样连接器如 Q-Former、Perceiver Resampler 则是在 _____ 空间聚合、压缩视觉语义信息。

三、解答题（本大题共 6 小题，共 60 分。解答应写出文字说明、证明过程或演算步骤。）

19.（本小题满分 10 分）

设 ViT 输入图像 $H \times W$ ，patch 大小 $P \times P$ ，隐藏维度 d ，注意力头数 h ，每头维度 $d_h = d/h$ ，编码器层数 L_{enc} 。

- (1) 推导 patch 数量 N_v 与总序列长度 N （含 CLS token）的表达式；（2 分）
- (2) 推导单层 ViT 编码器中 Self-Attention 前向传播的 FLOPs（含 Q, K, V 投影、 $QK^\top$ 、 $\text{softmax}(QK^\top)V$ 、输出投影），用 N, d, h 表示；（4 分）
- (3) 若图像分辨率从 224×224 提升至 448×448 （ P 不变），分析 N 、单层注意力 FLOPs 及注意力矩阵显存的变化倍数。（4 分）

20.（本小题满分 10 分）

CLIP 通过批内对比学习实现图文对齐。设 batch 大小为 B ，L2 归一化后的图像嵌入为 $\mathbf{I}_i$ ，文本嵌入为 $\mathbf{T}_i$ ，温度系数为 τ ，相似度 $s_{ij} = \mathbf{I}_i^\top \mathbf{T}_j / \tau$ 。

- (1) 写出 CLIP 对称 InfoNCE 损失的完整表达式（图像 $\rightarrow$ 文本与文本 $\rightarrow$ 图像两个方向）；（3 分）
- (2) 分析温度系数 τ 对 softmax 分布与梯度的影响： τ 增大和减小时分别有何效果？（3 分）
- (3) 对图像到文本方向，求 $\mathcal{L}_{I \rightarrow T}$ 关于正样本 logit s_{ii} 的梯度 $\partial \mathcal{L}_{I \rightarrow T} / \partial s_{ii}$ ，并解释其直觉含义。（4 分）

21. (本小题满分 10 分)

在多模态大模型中，为了同时处理文本、图像和视频，常采用多维旋转位置编码 (RoPE)。假设我们有一个 2×2 的图像，像素坐标 (h, w) 分别表示行和列， $h, w \in \{0, 1\}$ 。每个像素的特征向量为 4 维，前 2 维用高度编码，后 2 维用宽度编码。1D RoPE 对二维子向量的变换定义为

$$R_\theta \begin{pmatrix} a \\ b \end{pmatrix} = \begin{pmatrix} a \cos \theta - b \sin \theta \\ a \sin \theta + b \cos \theta \end{pmatrix}.$$

设高度基频 $\omega_h = 4\pi$ ，宽度基频 $\omega_w = 2\pi$ 。

- (1) 已知某像素位于坐标 $(1, 0)$ ，其原始特征向量为 $\mathbf{v} = [1, 0, 0, 1]^\top$ ，求经过 2D RoPE 编码后的向量。(3 分)
- (2) 已知一段 2 帧视频，每帧大小为 2×2 ，体素坐标 (t, h, w) ， $t \in \{0, 1\}$ 。现采用 M-RoPE，将特征向量拆分为时间、高度、宽度三组，每组 2 维。基频分别为 $\omega_t = 3\pi$ ， $\omega_h = 4\pi$ ， $\omega_w = 2\pi$ 。某体素位于 $(1, 0, 1)$ ，原始特征向量为 $\mathbf{u} = [1, 0, 0, 1, 1, 0]^\top$ (依次对应时间、高度、宽度组)，求 M-RoPE 编码后的向量。(3 分)
- (3) 将坐标 x 视为连续变量，频率 ω 取遍所有实数，且各频率权重相等。于是位置 x 的编码向量 (忽略幅度) 可视为函数 $\phi(x) = e^{i\omega x}$ 关于 ω 的连续族。对于任意两个位置 x 和 y ，求它们的编码内积 $K(x, y)$ 。(4 分)

22. (本小题满分 10 分)

LLaVA 将预训练视觉编码器 (如 CLIP ViT) 与 LLM 通过轻量投影器连接, 采用两阶段训练策略。

- (1) 画出 LLaVA 前向数据流: 从原始图像到 LLM 输出的完整路径, 标注视觉编码器、投影器、LLM 各阶段的输入输出维度变化; (4 分)
- (2) 对比阶段一 (特征对齐预训练) 与阶段二 (端到端指令微调) 的训练目标、冻结策略与数据形式; (3 分)
- (3) 若视觉编码器输出 $N_v = 576$ 个 token, LLM 最大上下文 4096 token, 用户文本平均 200 token。估算视觉 token 占上下文的比例, 并说明为何高分辨率场景下需要 AnyRes 或 token 压缩。(3 分)

23. (本小题满分 10 分)

BLIP-2 的 Q-Former 与 Flamingo 的 Perceiver Resampler 均通过可学习 query 压缩视觉特征。

- (1) 描述 Q-Former 的结构: 可学习 query 如何通过 Cross-Attention 从冻结 ViT 输出 $H_v \in \mathbb{R}^{N_v \times d_v}$ 中提取 N_q 个视觉 token; (4 分)
- (2) 对比 Q-Former 与 Flamingo Perceiver Resampler 的异同 (输入、注意力类型、输出用途); (3 分)
- (3) 设 $N_v = 1024$, $N_q = 64$, $d = 4096$, LLM 层数 $L = 32$ 。估算将 N_v 个 token 直接送入 LLM 与经 Q-Former 压缩后, LLM 侧 KV Cache 显存 (fp16) 的节省倍数。(3 分)

24. (本小题满分 10 分)

设 DDPM 前向过程为 $q(x_t|x_{t-1}) = \mathcal{N}(\sqrt{1-\beta_t}x_{t-1}, \beta_t I)$, $\alpha_t = 1 - \beta_t$, $\bar{\alpha}_t = \prod_{s=1}^t \alpha_s$ 。

- (1) 利用马尔可夫性质与重参数化技巧, 推导 $q(x_t|x_0) = \mathcal{N}(\sqrt{\bar{\alpha}_t}x_0, (1-\bar{\alpha}_t)I)$ 的完整过程; (5 分)
- (2) 说明为何训练目标可简化为 $\mathcal{L}_{\text{simple}} = \mathbb{E}_{t,x_0,\epsilon} [\|\epsilon - \epsilon_\theta(x_t, t)\|^2]$, 其中 $x_t = \sqrt{\bar{\alpha}_t}x_0 + \sqrt{1-\bar{\alpha}_t}\epsilon$, $\epsilon \sim \mathcal{N}(0, I)$ 。(5 分)

参考答案与解析

命题：大模型多模态课程组 校对：教研组

一、选择题答案

- | | | | |
|------|-------|-------|-------|
| 1. B | 2. C | 3. C | 4. B |
| 5. D | 6. B | 7. B | 8. A |
| 9. D | 10. A | 11. D | 12. B |

1. **B** CLIP 采用图像编码器与文本编码器双塔结构，批内 B 个图文对构成 $B \times B$ 相似度矩阵，对角线为正样本、非对角线为负样本，用 InfoNCE 对比损失训练。A 描述的是单塔融合架构；C 是像素级重建而非语义对齐；D 错误：ViT 可通过插值泛化到其他分辨率。

2. **C** Patch 数量 $N_v = (224/16)^2 = 14^2 = 196$ ，加 1 个 CLS token 后总序列长度 $N = 196 + 1 = 197$ 。

3. **C** 采样率 $16\text{ kHz} = 16000\text{ Hz}$ ，帧移 160 采样点，梅尔帧率 $= 16000/160 = 100$ 帧/秒。12 秒音频对应 $12 \times 100 = 1200$ 帧 Mel 特征。经两层 Stride=2 一维卷积，长度依次减半： $1200 \rightarrow 600 \rightarrow 300$ ，故 $L = 300$ ，选 C。A 为未卷积降采样长度；B 为仅一层 Stride=2；D 为三层降采样结果。

4. **B** LDM 先用 VAE 编码器将图像压缩为低维 z （如 $64 \times 64 \times 4$ ），在 z 空间训练 U-Net 去噪，解码时用 VAE 解码器还原图像，计算量远低于像素空间扩散。

5. **D** Late Fusion 虽简单，但无法在中间层捕获细粒度跨模态交互（如“图中红色物体”与“the red object”的 token 级对齐），Intermediate Fusion 在 VQA、Caption 等任务上通常更优。A、B、C 均为正确描述。

6. **B** LLaVA 用线性或 MLP 将 ViT 输出投影到 LLM 词嵌入空间；BLIP-2 用 Q-Former（可学习 query + 交叉注意力）桥接冻结 ViT 与 LLM；Flamingo 在 LLM 层间插入门控交叉注意力，使文本 token 查询视觉特征。

7. **B** 前向过程是马尔可夫链；当 $t \rightarrow T$ ， $\bar{\alpha}_t \rightarrow 0$ ， x_t 近似 $\mathcal{N}(0, I)$ 。反向 $q(x_{t-1}|x_t)$ 未知，需学习 $p_\theta(x_{t-1}|x_t)$ ； β_t 通常采用线性或 cosine 调度，非常数。

8. **A** VQ 将连续特征量化为 codebook 索引，argmax 不可微，常用 Straight-Through：前向用离散索引，反向梯度直通编码器输出。B 错误：DALL-E、Parti 等用离散 token + Transformer；C 错误：VQ 损失含 codebook、commitment、重建项；D 错误：码本过大易导致利用率低。

9. **D** FLUX 采用 Rectified Flow / Flow Matching 训练目标，区别于经典 DDPM 噪声预测损失；FLUX 为 Transformer 扩散主干（MMDiT 风格），非 SD 系列 U-Net；FLUX 在文字渲染、手部等细节场景口碑普遍优于 SDXL；FLUX.1 系列参数量与激活显存开销通常高于 SDXL，本地推理常见需求为 12GB 及以上显存。

10. **A** 多模态三要素：表示解决“如何编码各模态”；对齐解决“不同模态语义如何对应”；融合解决“多模态信息如何联合用于下游任务”。三者递进且相互关联。B 错误：三者含义不同；C 错误：推理时仍需 cross-attention 等融合；D 错误：VQA 等生成任务同样需要对齐。

11. **D** A、B、C 均为正确描述：GAN 对抗单步生成、易模式崩溃；VAE/早期 DALL-E 潜空间重建偏模糊；Parti/Muse 等 VQ 离散 token 自回归、不经扩散去噪。D 错误：AdaLN-Zero 是

DiT (Diffusion Transformer) 中的文本/条件调制方式; SD 1.5/XL 的 U-Net 主干主要通过**交叉注意力 (Cross-Attention)** 注入文本条件, 而非 AdaLN-Zero。SD3 的 MMDiT、FLUX 等虽为 Transformer 扩散主干, 其条件注入机制也与「全体主流模型均借助 AdaLN-Zero」的表述不符。

12. B 对角线 s_{ii} 为正样本; τ 越小 softmax 越尖锐, 对困难负样本梯度越大。A 错误: τ 小则分布更尖锐; C 错误: 图像—文本矩阵一般不对称 ($s_{ij} \neq s_{ji}$ 当使用不同编码器时); D 错误: $B = 1$ 无负样本, 对比学习失效。

二、填空题答案

13. $M^2 + ML + \frac{L(L+1)}{2}$ 。序列排列为 M 个图像 token 在前、 L 个文本 token 在后, 注意力矩阵规模为 $(M+L) \times (M+L)$ 。掩码规则为: (i) 图像部分不施加因果掩码, 图像 token 彼此可见; (ii) 文本部分施加因果掩码; (iii) 每个文本 token 可关注全部 M 个图像 token; 图像 token 不关注文本 token。

分块统计未被掩码元素:

- 图像 $\rightarrow$ 图像 ($M \times M$): 双向可见, 共 M^2 个;
- 图像 $\rightarrow$ 文本 ($M \times L$): 全部掩码, 0 个;
- 文本 $\rightarrow$ 图像 ($L \times M$): 每个文本 token 可见全部图像, 共 $L \times M = ML$ 个;
- 文本 $\rightarrow$ 文本 ($L \times L$): 因果下三角, 共 $1 + 2 + \dots + L = \frac{L(L+1)}{2}$ 个。

合计

$$M^2 + ML + \frac{L(L+1)}{2}.$$

14. $\sqrt{\frac{51}{50}}$ 。DDIM 在 $\sigma_t = 0$ (确定性采样) 时,

$$x_{t-1} = \sqrt{\alpha_{t-1}} \hat{x}_0 + \sqrt{1 - \alpha_{t-1}} \epsilon, \quad \hat{x}_0 = \frac{x_t - \sqrt{1 - \alpha_t} \epsilon}{\sqrt{\alpha_t}}.$$

代入并整理 x_t 的系数:

$$x_{t-1} = \sqrt{\frac{\alpha_{t-1}}{\alpha_t}} x_t + \left(\sqrt{1 - \alpha_{t-1}} - \sqrt{\frac{\alpha_{t-1}(1 - \alpha_t)}{\alpha_t}} \right) \epsilon.$$

故 x_{50} 的系数为 $\sqrt{\alpha_{49}/\alpha_{50}}$ 。由 $\alpha_t = 1 - 0.01t$ 得 $\alpha_{50} = 0.5, \alpha_{49} = 0.51$, 系数 $= \sqrt{0.51/0.5} = \sqrt{51/50}$ 。

15. $B(B-1)$ 。一个 batch 含 B 个图文匹配对, 共可构成 $B \times B = B^2$ 个图像—文本配对。其中对角线上的 B 个为正样本对 (i, i) ; 其余非对角线元素 (i, j) ($i \neq j$) 为负样本对, 共 $B^2 - B = B(B-1)$ 个。CLIP 对称 InfoNCE 在图像 $\rightarrow$ 文本与文本 $\rightarrow$ 图像两个方向均使用同一批内 $B \times B$ 相似度矩阵, 负样本对即该矩阵中的全部非对角元素。

16. $QK^\top$ 规模为 576×576 , fp16 显存 $= 576^2 \times 2 = 663552$ 字节 ≈ 0.66 MB, 保留整数为 1 MB。

17. $q(x_t|x_0) = \mathcal{N}(\sqrt{\alpha_t} x_0, (1 - \alpha_t)I)$ 。

18. 特征 (或语义特征/表征)。

三、解答题答案

19. ViT 计算量推导 (10 分)

(1) 序列长度 (2 分)

$N_v = \frac{H}{P} \cdot \frac{W}{P}$, 总序列长度 $N = N_v + 1$ (含 CLS)。

(2) 单层 Self-Attention FLOPs (4 分)

Q, K, V 投影: 各 $2Nd^2$, 共 $6Nd^2$ 。 $S = QK^\top$: $2N^2d$ 。 $O = \text{softmax}(S)V$: $2N^2d$ 。 输出投影: $2Nd^2$ 。
单层注意力合计 $\approx 8Nd^2 + 4N^2d$ FLOPs。

(3) 分辨率翻倍的影响 (4 分)

$224 \rightarrow 448$: N_v 从 $14^2 = 196$ 增至 $28^2 = 784$, 约 4 倍。 N 从 197 增至 785。 注意力 FLOPs 中 N^2d 项增约 $4^2 = 16$ 倍, Nd^2 项增 4 倍; 显存 $N \times N$ 注意力矩阵增 16 倍。 故高分辨率是视觉 token 爆炸的主要来源。

20. CLIP 对比学习 (10 分)

(1) 对称 InfoNCE (3 分)

$$\mathcal{L}_{I \rightarrow T} = -\frac{1}{B} \sum_{i=1}^B \log \frac{\exp(s_{ii})}{\sum_{j=1}^B \exp(s_{ij})}, \quad \mathcal{L}_{T \rightarrow I} = -\frac{1}{B} \sum_{j=1}^B \log \frac{\exp(s_{jj})}{\sum_{i=1}^B \exp(s_{ij})},$$

$$\mathcal{L}_{\text{CLIP}} = \frac{1}{2}(\mathcal{L}_{I \rightarrow T} + \mathcal{L}_{T \rightarrow I}).$$

(2) 温度 τ 的影响 (3 分)

τ 增大: logits s_{ij}/τ 变小, softmax 分布更平滑, 所有样本 (含负样本) 获得更均匀的梯度, 学习更稳定但区分力下降。 τ 减小: 分布更尖锐, 模型更关注困难负样本 (高相似度但不匹配的对), 梯度集中在少数样本, 有利于细粒度对齐但可能训练不稳定。 CLIP 典型 $\tau \approx 0.07$ 。

(3) 正样本 logit 梯度 (4 分)

记 $p_{ij} = \exp(s_{ij}) / \sum_k \exp(s_{ik})$, 则 $\mathcal{L}_{I \rightarrow T} = -\frac{1}{B} \sum_i \log p_{ii}$, 故

$$\frac{\partial \mathcal{L}_{I \rightarrow T}}{\partial s_{ii}} = -\frac{1}{B}(1 - p_{ii}).$$

p_{ii} 越接近 1 (正样本已很好区分), 梯度越接近 0; p_{ii} 小时梯度为负且绝对值大, 推动 s_{ii} 增大, 拉近正样本对。

21. 2D RoPE / M-RoPE 计算与连续核 (10 分)

(1) 2D RoPE 编码 (3 分)

像素坐标 $(h, w) = (1, 0)$, $\mathbf{v} = [v_1, v_2, v_3, v_4]^\top = [1, 0, 0, 1]^\top$ 。 2D RoPE 对高度、宽度子向量分别施加旋转, 旋转角为坐标乘以对应基频:

$$\theta_h = h \omega_h = 1 \times 4\pi = 4\pi, \quad \theta_w = w \omega_w = 0 \times 2\pi = 0.$$

高度组 (前两维 $[1, 0]^\top$):

$$R_{4\pi} \begin{pmatrix} 1 \\ 0 \end{pmatrix} = \begin{pmatrix} \cos 4\pi \cdot 1 - \sin 4\pi \cdot 0 \\ \sin 4\pi \cdot 1 + \cos 4\pi \cdot 0 \end{pmatrix} = \begin{pmatrix} 1 \\ 0 \end{pmatrix}.$$

宽度组（后两维 $[0, 1]^\top$ ）:

$$R_0 \begin{pmatrix} 0 \\ 1 \end{pmatrix} = \begin{pmatrix} \cos 0 \cdot 0 - \sin 0 \cdot 1 \\ \sin 0 \cdot 0 + \cos 0 \cdot 1 \end{pmatrix} = \begin{pmatrix} 0 \\ 1 \end{pmatrix}.$$

拼接得

$$\mathbf{v}' = [1, 0, 0, 1]^\top.$$

（本例中 4π 与 0 角均为 2π 整数倍，旋转退化为恒等变换。）

(2) M-RoPE 编码 (3 分)

体素坐标 $(t, h, w) = (1, 0, 1)$, $\mathbf{u} = [u_1, u_2, u_3, u_4, u_5, u_6]^\top = [1, 0, 0, 1, 1, 0]^\top$ 。三组旋转角:

$$\theta_t = t \omega_t = 3\pi, \quad \theta_h = h \omega_h = 0, \quad \theta_w = w \omega_w = 2\pi.$$

时间组 $[1, 0]^\top$: $\cos 3\pi = -1$, $\sin 3\pi = 0$,

$$R_{3\pi} \begin{pmatrix} 1 \\ 0 \end{pmatrix} = \begin{pmatrix} -1 \\ 0 \end{pmatrix}.$$

高度组 $[0, 1]^\top$: $\theta_h = 0$,

$$R_0 \begin{pmatrix} 0 \\ 1 \end{pmatrix} = \begin{pmatrix} 0 \\ 1 \end{pmatrix}.$$

宽度组 $[1, 0]^\top$: $\cos 2\pi = 1$, $\sin 2\pi = 0$,

$$R_{2\pi} \begin{pmatrix} 1 \\ 0 \end{pmatrix} = \begin{pmatrix} 1 \\ 0 \end{pmatrix}.$$

拼接得

$$\mathbf{u}' = [-1, 0, 0, 1, 1, 0]^\top.$$

(3) 连续频率编码内积 $K(x, y)$ (4 分)

Step 1: 定义内积核。

$$K(x, y) = \int_{-\infty}^{\infty} \phi(x, \omega) \overline{\phi(y, \omega)} d\omega = \int_{-\infty}^{\infty} e^{i\omega x} e^{-i\omega y} d\omega = \int_{-\infty}^{\infty} e^{i\omega(x-y)} d\omega.$$

Step 2: 傅里叶逆变换。

在分布（广义函数）意义下:

$$\int_{-\infty}^{\infty} e^{i\omega(x-y)} d\omega = 2\pi \delta(x-y).$$

其中 $\delta(\cdot)$ 为狄拉克函数。

Step 3: 结论与意义。

$$K(x, y) = 2\pi \delta(x-y).$$

内积仅依赖相对位置 $x-y$ 。离散 RoPE 用有限频率 θ_k 逼近该核，得 $K(x, y) \approx \sum_k \cos((x-y)\theta_k)$ ，与 (1)(2) 中 $\cos \theta$ 、 $\sin \theta$ 的旋转形式一致。（推导毕）

22. LLaVA 架构与训练 (10 分)**(1) 数据流 (4 分)**

原始图像 $\rightarrow$ 视觉编码器 $\rightarrow$ 投影器 $\rightarrow$ LLM (结合文本输入) $\rightarrow$ LLM 自回归输出。

各阶段张量维度: 图像经 ViT 编码为 $[N_v \times d_v]$; 投影器映射为 $[N_v \times d_{\text{LLM}}]$, 再与文本 token 嵌入拼接后送入 LLM。其中 N_v 为视觉 token 数 (如 patch 数 + CLS), d_v 为视觉编码器隐藏维度, d_{LLM} 为 LLM 词嵌入维度。

(2) 两阶段对比 (3 分)

阶段一: 冻结 ViT 与 LLM, 只训练投影器, 用图文对 (如 CC3M) 做 next-token 预测, 学习视觉—语言对齐。阶段二: 解冻 LLM (或 LoRA), 用指令数据 (VQA、对话) 端到端微调, 学习遵循指令与推理。

(3) Token 预算 (3 分)

视觉占比 $= 576 / (576 + 200) \approx 74\%$ 。高分辨率时 N_v 可超 2k, 易占满 4k 上下文, 需 AnyRes 切图后选择性编码, 或 2×2 pooling 合并 token, 或 Q-Former 压缩。

23. Q-Former 与 Perceiver Resampler (10 分)**(1) Q-Former 结构 (4 分)**

N_q 个可学习 query $\mathbf{Q} \in \mathbb{R}^{N_q \times d}$ 作为 Query, ViT 输出 H_v 作为 Key/Value, 经 Cross-Attention: $\text{Attn}(\mathbf{Q}, H_v, H_v)$, 输出 N_q 个视觉 token。ViT 冻结, 只训练 Q-Former 与后续 LLM 接口。

(2) 异同 (3 分)

Q-Former: 独立 BERT 式模块, 输出接 LLM 投影; Flamingo Perceiver Resampler: 在 Flamingo 框架内, 用固定数量 latent 查询视觉特征, 输出注入 LLM 交叉注意力层。二者均为“少量 query + Cross-Attn”压缩, 但集成方式不同。

(3) KV Cache 节省 (3 分)

LLM KV Cache 与序列长度成正比。直接输入: $N_v = 1024$; 压缩后: $N_q = 64$ 。节省倍数 $= 1024 / 64 = 16$ 。32 层 fp16: 约 $2 \times L \times N \times d \times 2$ 字节, 序列减 16 倍则 KV Cache 减 16 倍。

24. 扩散模型推导 (10 分)**(1) $q(x_t|x_0)$ 闭式解推导 (5 分)**

Step 1: 写出单步重参数化形式。

由题设前向马尔可夫过程

$$q(x_t|x_{t-1}) = \mathcal{N}\left(\sqrt{1 - \beta_t} x_{t-1}, \beta_t I\right), \quad \alpha_t = 1 - \beta_t,$$

可重参数化为

$$x_t = \sqrt{\alpha_t} x_{t-1} + \sqrt{1 - \alpha_t} \epsilon_{t-1}, \quad \epsilon_{t-1} \sim \mathcal{N}(0, I).$$

Step 2: 递推至 x_1 。

$$x_1 = \sqrt{\alpha_1} x_0 + \sqrt{1 - \alpha_1} \epsilon_0.$$

Step 3: 递推至 x_2 并观察系数规律。

$$\begin{aligned}
x_2 &= \sqrt{\alpha_2} x_1 + \sqrt{1 - \alpha_2} \epsilon_1 \\
&= \sqrt{\alpha_2} (\sqrt{\alpha_1} x_0 + \sqrt{1 - \alpha_1} \epsilon_0) + \sqrt{1 - \alpha_2} \epsilon_1 \\
&= \sqrt{\alpha_1 \alpha_2} x_0 + \underbrace{\sqrt{\alpha_2(1 - \alpha_1)} \epsilon_0 + \sqrt{1 - \alpha_2} \epsilon_1}_{\text{两个独立高斯的线性组合}}.
\end{aligned}$$

因 ϵ_0, ϵ_1 独立标准高斯，其线性组合仍为零均值高斯，方差为

$$\alpha_2(1 - \alpha_1) + (1 - \alpha_2) = 1 - \alpha_1 \alpha_2.$$

故可写为 $x_2 = \sqrt{\bar{\alpha}_2} x_0 + \sqrt{1 - \bar{\alpha}_2} \bar{\epsilon}_1$ ，其中 $\bar{\alpha}_2 = \alpha_1 \alpha_2$ ， $\bar{\epsilon}_1 \sim \mathcal{N}(0, I)$ 。

Step 4: 数学归纳法推广到一般 t 。

设 $\bar{\alpha}_t = \prod_{s=1}^t \alpha_s$ ，且已有

$$x_{t-1} = \sqrt{\bar{\alpha}_{t-1}} x_0 + \sqrt{1 - \bar{\alpha}_{t-1}} \bar{\epsilon}_{t-2}.$$

则

$$\begin{aligned}
x_t &= \sqrt{\alpha_t} x_{t-1} + \sqrt{1 - \alpha_t} \epsilon_{t-1} \\
&= \sqrt{\alpha_t \bar{\alpha}_{t-1}} x_0 + \sqrt{\alpha_t(1 - \bar{\alpha}_{t-1})} \bar{\epsilon}_{t-2} + \sqrt{1 - \alpha_t} \epsilon_{t-1}.
\end{aligned}$$

注意到 $\alpha_t \bar{\alpha}_{t-1} = \bar{\alpha}_t$ 。噪声项方差为

$$\alpha_t(1 - \bar{\alpha}_{t-1}) + (1 - \alpha_t) = 1 - \alpha_t \bar{\alpha}_{t-1} = 1 - \bar{\alpha}_t.$$

因此

$$x_t = \sqrt{\bar{\alpha}_t} x_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon, \quad \epsilon \sim \mathcal{N}(0, I).$$

即任意 t 步后，条件分布为

$$q(x_t | x_0) = \mathcal{N}(\sqrt{\bar{\alpha}_t} x_0, (1 - \bar{\alpha}_t)I).$$

当 $t \rightarrow T$ 且 $\bar{\alpha}_T \rightarrow 0$ 时， $x_T \approx \mathcal{N}(0, I)$ ，实现向纯噪声的渐进破坏。（推导毕）

(2) 训练目标简化为噪声预测 (5 分)

Step 1: 变分下界的原始形式。

DDPM 训练目标是最大化数据对数似然 $\log p_\theta(x_0)$ ，等价于最小化变分下界 (ELBO)。对每一步去噪分布 $p_\theta(x_{t-1} | x_t)$ 与真实后验 $q(x_{t-1} | x_t, x_0)$ 的 KL 散度可写为（省略常数项）：

$$\mathcal{L}_{\text{VLB}} = \mathbb{E}_q \left[\sum_{t=1}^T D_{\text{KL}}(q(x_{t-1} | x_t, x_0) \parallel p_\theta(x_{t-1} | x_t)) \right] + \text{const.}$$

其中真实后验 $q(x_{t-1} | x_t, x_0)$ 在已知 x_0 时有闭式高斯解，其均值是 x_0 与 x_t 的线性组合。

Step 2: 由 (1) 建立 x_0 与 ϵ 的一一对应。

对采样 t 、数据 x_0 、噪声 $\epsilon \sim \mathcal{N}(0, I)$ ，定义

$$x_t = \sqrt{\bar{\alpha}_t} x_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon.$$

由于 $\bar{\alpha}_t > 0$ ，可反解

$$x_0 = \frac{1}{\sqrt{\bar{\alpha}_t}} (x_t - \sqrt{1 - \bar{\alpha}_t} \epsilon).$$

故给定 (x_t, t) 时，预测 x_0 、预测 ϵ 、预测 x_{t-1} 三者参数化等价，可互相线性变换。

Step 3: 将 KL 项改写为均方误差。

Ho 等 (DDPM) 证明: 在参数化

$$p_{\theta}(x_{t-1}|x_t) = \mathcal{N}(\mu_{\theta}(x_t, t), \sigma_t^2 I)$$

且选取与 q 匹配的方差 σ_t^2 时, 第 t 步 KL 项 (忽略权重系数) 等价于

$$\|\tilde{\mu}_t(x_t, x_0) - \mu_{\theta}(x_t, t)\|^2,$$

其中 $\tilde{\mu}_t$ 为 $q(x_{t-1}|x_t, x_0)$ 的均值。将 $\tilde{\mu}_t$ 用 ϵ 表示后, 可进一步化为

$$\|\epsilon - \epsilon_{\theta}(x_t, t)\|^2.$$

即网络直接预测注入噪声 ϵ , 与预测均值 μ_{θ} 或预测 x_0 在数学上等价。

Step 4: 得到 Simple Loss 及其优点。

对 t 均匀采样, 最终常用的简化训练目标为

$$\mathcal{L}_{\text{simple}} = \mathbb{E}_{t \sim \mathcal{U}\{1, \dots, T\}, x_0, \epsilon} \left[\|\epsilon - \epsilon_{\theta}(x_t, t)\|^2 \right].$$

相比完整 VLB: (i) **实现简单**, 只需对加噪样本回归噪声; (ii) **训练稳定**, 各 t 步梯度尺度更均衡; (iii) **效果相当**, 实践中与加权 VLB 生成质量接近。Stable Diffusion 等 latent 扩散模型在隐空间 z 上沿用同一套 ϵ -prediction 范式。(推导毕)