

大模型微调与 RLHF 对齐期末试卷

满分 150 分 考试时间 150 分钟

注意事项：

- 本试卷共 三大题，包括选择题、填空题、解答题，共 **24** 小题。
- 请将答案写在答题区指定位置；解答题须写出必要的文字说明、推导过程或演算步骤。
- 涉及数学公式推导时，请清晰写出关键中间步骤；只写最终结果不得分。
- 本试卷中如无特殊说明，基座模型参数量记为 Φ ，隐藏维度记为 d ，LoRA 秩记为 r ，序列长度记为 L ，批大小记为 B ，词表大小记为 V ，参考模型记为 π_{ref} ，策略模型记为 π_{θ} ，奖励模型输出记为 $r_{\phi}(x, y)$ 。

一、选择题（本大题共 12 小题，每小题 5 分，共 60 分。在每小题给出的四个选项中，只有一项是符合题目要求的。）

1. 关于 LoRA (Low-Rank Adaptation) 的核心思想，下列说法正确的是

- (A) LoRA 通过全量更新权重矩阵 $W \in \mathbb{R}^{d_{\text{out}} \times d_{\text{in}}}$ 来适配下游任务
- (B) LoRA 冻结预训练权重 W ，仅训练低秩增量 $\Delta W = BA$ ，其中 $B \in \mathbb{R}^{d_{\text{out}} \times r}$ ， $A \in \mathbb{R}^{r \times d_{\text{in}}}$ ，且通常 $r \ll \min(d_{\text{in}}, d_{\text{out}})$
- (C) LoRA 只能应用于 Transformer 的 MLP 层，不能用于注意力投影层
- (D) LoRA 训练完成后必须将 BA 永久合并进 W ，否则无法推理

2. 在指令微调 (Instruction Tuning / SFT) 中，对形如「用户指令 + 模型回复」的样本，标准做法是对 Loss 施加因果掩码并

- (A) 对指令部分与回复部分均计算 next-token 预测损失
- (B) 仅对回复部分计算 next-token 预测损失，指令部分 token 不参与 Loss 计算
- (C) 仅对指令部分计算 Loss，以强化模型对指令的理解
- (D) 对指令与回复分别计算两个独立的交叉熵损失再相加

3. 经典 RLHF 对齐流水线 (InstructGPT / ChatGPT 风格) 的三个阶段，其正确顺序是

- (A) SFT $\rightarrow$ PPO 强化学习 $\rightarrow$ 奖励模型训练
- (B) 奖励模型训练 $\rightarrow$ SFT $\rightarrow$ PPO 强化学习
- (C) SFT $\rightarrow$ 奖励模型训练 $\rightarrow$ PPO 强化学习
- (D) PPO 强化学习 $\rightarrow$ SFT $\rightarrow$ 奖励模型训练

4. QLoRA 在单卡上微调 65B 级模型的关键设计不包括

- (A) 对冻结的基座权重做 4-bit NormalFloat (NF4) 量化

- (B) 使用双重量化 (Double Quantization) 进一步压缩量化常数
- (C) 在 GPU 上通过分页优化器 (Paged Optimizer) 管理优化器状态
- (D) 将 LoRA 适配器也量化为 INT4 且不再保留 FP16 梯度

5. 下列 PEFT (Parameter-Efficient Fine-Tuning) 方法中, 推理阶段不引入额外延迟 (即无需额外前向模块) 的是

- (A) Prefix Tuning (在输入前拼接可学习前缀向量)
- (B) Adapter (在 FFN 中插入瓶颈层)
- (C) LoRA (训练后将 BA 合并进 W)
- (D) Prompt Tuning (仅在输入嵌入层添加 soft prompt)

6. 奖励模型 (Reward Model, RM) 通常基于 Bradley-Terry 偏好模型训练。给定提示 x , 偏好回答 y_w 优于 y_l , 模型输出标量奖励 $r_\phi(x, y)$, 则标准 RM 损失为

- (A) $-\log \sigma(r_\phi(x, y_w) - r_\phi(x, y_l))$
- (B) $-\log \sigma(r_\phi(x, y_l) - r_\phi(x, y_w))$
- (C) $\|r_\phi(x, y_w) - 1\|^2 + \|r_\phi(x, y_l) + 1\|^2$
- (D) $-\log \pi_\phi(y_w|x) - \log(1 - \pi_\phi(y_l|x))$

7. 在 RLHF 的 PPO 阶段, 设旧策略 π_{old} , 当前策略 π_θ , 优势函数 A_t , 裁剪阈值 $\epsilon = 0.2$ 。则 PPO-Clip 目标中, 单样本贡献为 $\min(r_t(\theta)A_t, \text{clip}(r_t(\theta), 1 - \epsilon, 1 + \epsilon)A_t)$, 其中 $r_t(\theta)$ 定义为

- (A) $\frac{\pi_{\text{old}}(a_t|s_t)}{\pi_\theta(a_t|s_t)}$
- (B) $\frac{\pi_\theta(a_t|s_t)}{\pi_{\text{old}}(a_t|s_t)}$
- (C) $\frac{\pi_\theta(a_t|s_t)}{\pi_{\text{ref}}(a_t|s_t)}$
- (D) $\exp(\pi_\theta(a_t|s_t) - \pi_{\text{old}}(a_t|s_t))$

8. DPO (Direct Preference Optimization) 相对传统 RLHF-PPO 的主要优势是

- (A) 完全不需要偏好数据, 仅依赖无标注文本
- (B) 无需单独训练奖励模型与 PPO 循环, 直接在偏好对上优化策略, 且隐式包含 KL 约束
- (C) 保证微调后模型在预训练 perplexity 上一定优于基座模型
- (D) 训练过程中不需要保存参考模型 π_{ref}

9. 关于全量微调 (Full Fine-Tuning) 与 LoRA 的对比, 下列说法错误的是

- (A) 全量微调在下游数据量较小时更容易出现灾难性遗忘 (Catastrophic Forgetting)
- (B) LoRA 的 A 矩阵通常采用高斯初始化, B 矩阵初始化为零, 使训练初期 $\Delta W = BA \approx 0$
- (C) LoRA 的秩 r 越大, 可训练参数量与表达能力通常越强, 但收益存在边际递减
- (D) LoRA 微调后模型在相同数据上的收敛速度一定快于全量微调, 因为参数量更少

10. SimPO (Simple Preference Optimization) 相对 DPO 的一个关键改进是

- (A) 引入额外的价值网络 (Value Network) 估计优势函数
- (B) 用序列平均 log-probability 的差值作为隐式奖励, 并去掉对参考模型 π_{ref} 的依赖
- (C) 将 PPO 的裁剪机制直接嵌入 SFT 损失
- (D) 仅支持多轮对话数据, 不支持单轮偏好对

11. RLHF 中常见的「奖励黑客 (Reward Hacking)」现象, 其最本质的成因是

- (A) 奖励模型训练数据量不足
- (B) 奖励模型仅是 $r_\phi(x, y)$ 的标量近似, 策略优化会在 π_θ 支撑集上最大化该代理目标, 从而偏离真实人类偏好
- (C) PPO 裁剪阈值 ϵ 设置过大
- (D) SFT 阶段学习率过高

12. KTO (Kahneman-Tversky Optimization) 相对 DPO 的数据与目标假设, 下列说法正确的是

- (A) KTO 必须使用成对偏好数据 (y_w, y_l) , 与 DPO 完全相同
- (B) KTO 基于前景理论, 可仅利用带标签的单回复数据 (good/bad), 无需严格成对采样
- (C) KTO 仅适用于多模态对齐, 不适用于纯文本 LLM
- (D) KTO 在数学上等价于 PPO-Clip, 只是实现更高效

二、填空题 (本大题共 6 小题, 每小题 5 分, 共 30 分。把答案填在题中横线上。)

13. LoRA 前向传播为 $h = Wx + \frac{\alpha}{r}BAx$ 。若秩 $r = 8$, 缩放因子 $\alpha = 16$, 则 LoRA 分支的有效缩放系数为 _____。

14. 对某线性层 $W \in \mathbb{R}^{4096 \times 4096}$ 施加 LoRA ($r = 16$), 该层 LoRA 可训练参数数量为 _____ (用整数表示)。

15. 在 RLHF-PPO 中, 优势函数 A_t 常用 GAE (Generalized Advantage Estimation) 估计: $A_t = \sum_{l=0}^{\infty} (\gamma\lambda)^l \delta_{t+l}$, 其中 TD 残差 $\delta_t =$ _____。

16. DPO 损失中, β 控制策略偏离参考模型的强度。当 $\beta \rightarrow +\infty$ 时, 最优策略将 _____; 当 $\beta \rightarrow 0$ 时, 模型主要 _____。

17. SFT 微调使用全局批大小 128, 8 张 GPU 数据并行, 每卡微批大小为 2, 则梯度累积步数为 _____。

18. 设词表大小 $V = 2$, 某 prompt x 下, 参考模型 $\pi_{\text{ref}}(A|x) = \pi_{\text{ref}}(B|x) = 0.5$; SFT 后策略 $\pi_\theta(A|x) = 0.9$, $\pi_\theta(B|x) = 0.1$ 。则 $D_{\text{KL}}(\pi_\theta \parallel \pi_{\text{ref}}) \approx$ _____ (取 $\ln 3 \approx 1.10$, $\ln 5 \approx 1.61$, 保留两位小数)。

三、解答题 (本大题共 6 小题, 共 60 分。解答应写出文字说明、证明过程或演算步骤。)

19. (本小题满分 10 分)

LoRA 将权重更新限制为低秩形式。设原线性层 $y = Wx$, $W \in \mathbb{R}^{d_{\text{out}} \times d_{\text{in}}}$, LoRA 引入 $\Delta W = BA$, $B \in \mathbb{R}^{d_{\text{out}} \times r}$, $A \in \mathbb{R}^{r \times d_{\text{in}}}$ 。

- (1) 写出 LoRA 修改后的前向公式, 并说明为何初始化 $A \sim \mathcal{N}(0, \sigma^2)$ 、 $B = 0$ 能使训练初始阶段输出与预训练模型一致; (3 分)
- (2) 推导该层 LoRA 可训练参数量, 并与全量微调该层的参数量对比, 给出压缩比 (用 $d_{\text{in}}, d_{\text{out}}, r$ 表示); (4 分)
- (3) 说明 LoRA 通常作用于 W_Q, W_K, W_V, W_O 而非 MLP 的全部矩阵时, 工程上如何权衡效果与显存。 (3 分)

20. (本小题满分 10 分)

指令微调样本格式为: `<|user|>` 问题 `<|assistant|>` 回答。设 token 序列长度为 L , 其中前 L_u 个 token 属于用户指令 (含模板 token), 后 $L_a = L - L_u$ 个 token 属于助手回复。

- (1) 写出带掩码的 SFT 损失函数 $\mathcal{L}_{\text{SFT}}$ (对回复部分每个 token 做 next-token 预测); (3 分)
- (2) 解释为何不能对指令部分也计算 Loss (从「教模型生成回答」vs「教模型复述指令」两个角度); (3 分)
- (3) 若采用 packing (将多条短样本拼接为一个长序列), 需要额外引入哪些机制防止样本间互相可见? (4 分)

21. (本小题满分 10 分)

奖励模型 $r_\phi(x, y)$ 在偏好数据集 $\mathcal{D} = \{(x^{(i)}, y_w^{(i)}, y_l^{(i)})\}$ 上训练, Bradley-Terry 模型假设 $P(y_w \succ y_l | x) = \sigma(r_\phi(x, y_w) - r_\phi(x, y_l))$ 。

- (1) 写出负对数似然损失 $\mathcal{L}_{\text{RM}}(\phi)$ 并解释每一项的直觉含义; (4 分)
- (2) 说明 RM 训练完成后, 在 PPO 阶段如何使用 r_ϕ 构造逐步奖励 (token-level reward); (3 分)
- (3) 列举 RM 常见的两个失效模式 (如长度偏置、风格偏置), 并各给一条缓解策略。 (3 分)

22. (本小题满分 10 分)

RLHF 中 PPO 阶段优化目标 (忽略价值函数与熵 bonus) 为:

$$\max_{\theta} \mathbb{E}_{x \sim \mathcal{D}, y \sim \pi_{\theta}(\cdot|x)} \left[r_{\phi}(x, y) - \beta \log \frac{\pi_{\theta}(y|x)}{\pi_{\text{ref}}(y|x)} \right].$$

- (1) 解释 KL 惩罚项 $-\beta \log \frac{\pi_{\theta}}{\pi_{\text{ref}}}$ 的作用, 以及 β 过大/过小分别会导致什么现象; (4 分)
- (2) 将上式改写为 PPO-Clip 可优化的形式: 定义 $r_t(\theta) = \frac{\pi_{\theta}(y_t|x, y_{<t})}{\pi_{\text{old}}(y_t|x, y_{<t})}$, 写出 Clip 目标并说明为何需要「裁剪」; (4 分)
- (3) 说明参考模型 π_{ref} 与 PPO 中旧策略 π_{old} 的区别与联系。(2 分)

23. (本小题满分 10 分)

DPO 将 RLHF 的约束优化问题

$$\max_{\pi} \mathbb{E}[r(x, y)] - \beta D_{\text{KL}}(\pi \| \pi_{\text{ref}})$$

转化为在偏好数据上的分类损失。设人类偏好 $y_w \succ y_l$ 满足 $P(y_w \succ y_l | x) = \sigma(r(x, y_w) - r(x, y_l))$ 。

- (1) 写出最优策略 $\pi^*(y|x)$ 的闭式解 (含配分函数 $Z(x)$); (3 分)
- (2) 利用 $\log \frac{\pi^*(y|x)}{\pi_{\text{ref}}(y|x)} = \frac{r(x,y)}{\beta} - \log Z(x)$, 消去 $r(x, y)$, 推导 DPO 损失; (5 分)
- (3) 对比 DPO 与 RLHF-PPO 在工程实现上的三个主要差异。(2 分)

24. (本小题满分 10 分, 压轴)

某团队需将 7B 基座模型对齐为「有帮助、无害、诚实」的对话助手。资源: 单台 $8 \times A100-80GB$ 节点; 数据: 10k 高质量指令 SFT 样本、50k 成对偏好数据、5k 安全拒绝样本 (有害请求 + 安全回复)。基座模型 fp16 权重约 14GB。

- (1) 设计完整对齐流水线 (阶段顺序、每阶段目标与数据), 并说明为何该顺序合理; (4 分)
- (2) 在 QLoRA ($r = 64$, 4-bit 基座 + bf16 LoRA) 与全量 SFT 之间做出选择并量化估算 7B 模型在 8 卡上的可训练性与显存占用 (需写出主要显存项); (3 分)
- (3) 针对「过度拒绝 (Over-refusal)」与「越狱 (Jailbreak)」两类对齐失败, 各提出一条可落地的数据或算法缓解方案, 并说明预期副作用。 (3 分)

参考答案与解析

命题：大模型微调与 RLHF 对齐课程组 校对：教研组

一、选择题答案

- | | | | |
|------|-------|-------|-------|
| 1. B | 2. B | 3. C | 4. D |
| 5. C | 6. A | 7. B | 8. B |
| 9. D | 10. B | 11. B | 12. B |

- B** LoRA 冻结 W ，只训练低秩 BA ， $r \ll d$ 时参数量远小于全量微调。A 描述全量微调；C 错误：LoRA 广泛用于 W_Q, W_K, W_V, W_O 及 MLP；D 错误：推理时可动态计算 BAx 或合并后推理。
- B** 标准 Instruction SFT 只对助手回复部分计算 next-token CE Loss，避免模型学习「复述用户指令」。A/C/D 均不符合主流做法（Alpaca、LLaMA-Factory 等）。
- C** 经典 RLHF：先用 SFT 教会基本指令跟随，再训 RM 学偏好，最后用 PPO 在 RM 信号下优化策略。
- D** QLoRA 量化冻结基座权重（NF4），LoRA 适配器通常保持 bf16/fp16 可训练精度；D 错误地把 LoRA 也 INT4 化且不含 FP16 梯度，不符合 QLoRA 原论文设计。
- C** LoRA 训练结束后可将 BA 合并进 W ，推理无额外模块。Prefix/Prompt Tuning 需拼接额外 token；Adapter 需额外前向层。
- A** Bradley-Terry 偏好概率 $P(y_w \succ y_l | x) = \sigma(r_w - r_l)$ ，负对数似然即 $-\log \sigma(r_\phi(x, y_w) - r_\phi(x, y_l))$ 。
- B** PPO 重要性采样比 $r_t(\theta) = \pi_\theta(a_t | s_t) / \pi_{\text{old}}(a_t | s_t)$ 。C 是 KL 惩罚中的参考策略比，非 PPO ratio。
- B** DPO 直接在偏好对上优化，隐式 KL 约束，无需 RM + PPO 循环。A 错误：DPO 需要偏好数据；C 无保证；D 错误：DPO 需要 π_{ref} 计算 log-ratio。
- D** LoRA 参数量少但每步更新维度低，收敛速度不一定更快；小数据全量微调更易遗忘预训练能力。A、B、C 均为正确描述。
- B** SimPO 用 $\frac{\beta}{|y|} \log \pi_\theta(y|x)$ 的差分作隐式奖励，去掉参考模型。A 描述 PPO；C 混淆；D 错误。
- B** RM 是代理目标，策略优化会 exploit RM 漏洞（如堆砌正面词、过长回答），本质上是「优化错误目标」。
- B** KTO 基于前景理论，支持非成对的 good/bad 单回复标签，是 DPO 的重要扩展。

二、填空题答案

- 2 有效缩放 $= \alpha / r = 16 / 8 = 2$ 。
- 131072 LoRA 参数 $= r(d_{\text{in}} + d_{\text{out}}) = 16 \times (4096 + 4096) = 131072$ 。
- $r_t + \gamma V(s_{t+1}) - V(s_t)$ 其中 r_t 为即时奖励；GAE 通过 λ 在偏差与方差间折中。
- 退化为参考模型 π_{ref} （或「几乎不改变参考策略」）；完全最大化奖励而忽略 KL 约束（或「严重偏离参考模型」）。

17. $8 \times 128 = 8 \times 2 \times \text{Steps} \Rightarrow \text{Steps} = 8。$

18. $0.37 \quad D_{\text{KL}} = 0.9 \ln(0.9/0.5) + 0.1 \ln(0.1/0.5) = 0.9(\ln 9 - \ln 5) + 0.1(-\ln 5) = 1.8 \ln 3 - \ln 5 \approx 1.98 - 1.61 = 0.37。$

三、解答题答案

19. LoRA 原理 (10 分)

(1) 前向与初始化 (3 分)

修改后: $y = Wx + \frac{\alpha}{r}BAx$ 。 $B = 0$ 时 $BA = 0$, 故 $\Delta y = 0$, 输出等于原 Wx , 训练从预训练权重「零扰动」起步, 保证初始 loss 与基座一致, 优化更稳定。

(2) 参数量与压缩比 (4 分)

LoRA 可训练参数 $= r(d_{\text{in}} + d_{\text{out}})$; 全量微调 $= d_{\text{in}}d_{\text{out}}$ 。 压缩比

$$\frac{d_{\text{in}}d_{\text{out}}}{r(d_{\text{in}} + d_{\text{out}})}.$$

例: 4096×4096 层, $r = 16$, 压缩比 $\approx 4096/32 = 128$ 倍。

(3) 工程权衡 (3 分)

W_Q, W_V 通常收益最高; 加 W_K, W_O 进一步提升但参数翻倍。 MLP 层 ($d \times 4d$) 参数更多, 对显存敏感场景可只对 Attention 做 LoRA; 若效果不足再扩至 MLP 或增大 r 。

20. 指令微调 SFT (10 分)

(1) 带掩码损失 (3 分)

$$\mathcal{L}_{\text{SFT}} = - \sum_{t=L_u+1}^L \log p_{\theta}(y_t | x, y_{<t}),$$

等价于对 $t \leq L_u$ 的 token 令 loss mask 为 0。

(2) 为何不 mask 指令 (3 分)

若对指令也算 Loss, 模型被训练成「续写/复述用户输入」, 而非「生成助手回复」; 推理时用户输入已给定, 对指令算 loss 浪费容量且可能导致错误行为 (如重复用户问题)。

(3) Packing 机制 (4 分)

需引入 **segment ID** / **attention mask**, 使同一样本内 token 可互相 attend, 不同样本间不可见 (Block-Diagonal Mask); 通常还需 **position ID 重置**, 避免跨样本位置编码串联; FlashAttention 变体需支持 variable-length / cu-seqlen 接口。

21. 奖励模型 (10 分)

(1) RM 损失 (4 分)

$$\mathcal{L}_{\text{RM}}(\phi) = -\mathbb{E}_{(x, y_w, y_l) \sim \mathcal{D}} [\log \sigma(r_{\phi}(x, y_w) - r_{\phi}(x, y_l))].$$

最大化偏好对的对数几率: $r_w - r_l$ 越大, y_w 优于 y_l 的概率越高。

(2) Token-level 奖励 (3 分)

常见做法：仅在最后一个 token 处给予 $r_\phi(x, y)$ ，其余 token 奖励为 0；或用 KL 惩罚构造逐步 reward： $r_t = \text{RM_end}(x, y) \cdot \mathbf{1}_{t=T} - \beta \log \frac{\pi_\theta(y_t|y_{<t}, x)}{\pi_{\text{ref}}(y_t|y_{<t}, x)}$ 。

(3) 失效模式与缓解 (3 分)

长度偏置：RM 偏好更长回答 $\Rightarrow$ 训练时对长度做归一化或惩罚超长样本。风格偏置：RM 偏好列表/敬语 $\Rightarrow$ 增加多样化偏好数据、对抗性数据增强。

22. PPO 与 KL 惩罚 (10 分)

(1) KL 惩罚作用 (4 分)

限制 π_θ 不偏离 π_{ref} 太远，保持流畅性与多样性，防止 reward hacking。 β 过大：策略几乎不动，对齐效果弱； β 过小：策略偏离过大，输出退化/重复/乱码。

(2) PPO-Clip 形式 (4 分)

$$\mathcal{L}^{\text{CLIP}} = \mathbb{E}[\min(r_t(\theta)A_t, \text{clip}(r_t(\theta), 1 - \epsilon, 1 + \epsilon)A_t)].$$

裁剪防止 r_t 偏离 1 太远时梯度爆炸，保证多轮 on-policy 更新稳定。

(3) π_{ref} vs π_{old} (2 分)

π_{ref} 固定为 SFT 模型，提供 KL 锚点； π_{old} 每轮 PPO 更新前复制自当前 π_θ ，用于重要性采样。前者约束长期偏离，后者约束单次更新步长。

23. DPO 推导 (10 分)

(1) 闭式最优解 (3 分)

$$\pi^*(y|x) = \frac{1}{Z(x)} \pi_{\text{ref}}(y|x) \exp\left(\frac{r(x, y)}{\beta}\right), \quad Z(x) = \sum_y \pi_{\text{ref}}(y|x) \exp\left(\frac{r(x, y)}{\beta}\right).$$

(2) DPO 损失推导 (5 分)

由 $\log \frac{\pi^*(y|x)}{\pi_{\text{ref}}(y|x)} = \frac{r(x, y)}{\beta} - \log Z(x)$ ，得 $r(x, y) = \beta \log \frac{\pi^*(y|x)}{\pi_{\text{ref}}(y|x)} + \beta \log Z(x)$ 。代入 Bradley-Terry：

$$P(y_w \succ y_l|x) = \sigma\left(\beta \log \frac{\pi^*(y_w|x)}{\pi_{\text{ref}}(y_w|x)} - \beta \log \frac{\pi^*(y_l|x)}{\pi_{\text{ref}}(y_l|x)}\right).$$

用 π_θ 替换 π^* ，极大似然得

$$\mathcal{L}_{\text{DPO}} = -\mathbb{E}\left[\log \sigma\left(\beta \log \frac{\pi_\theta(y_w|x)}{\pi_{\text{ref}}(y_w|x)} - \beta \log \frac{\pi_\theta(y_l|x)}{\pi_{\text{ref}}(y_l|x)}\right)\right].$$

$Z(x)$ 在作差时消去。

(3) 工程差异 (2 分)

DPO：无 RM、无 PPO 采样循环、实现简单；但需存 π_{ref} 做 log-ratio，离线更新。PPO：需 RM + 在线 rollout + value head，显存与系统复杂度高，但更灵活（可接规则奖励）。

24. 对齐流水线综合设计 (10 分)

(1) 流水线设计 (4 分)

推荐：SFT（10k 指令，学会格式与基本能力） $\rightarrow$ RM 或直接 DPO（50k 偏好，学人类偏好） $\rightarrow$ 安全 SFT / 拒绝微调（5k 安全样本，强化无害性） $\rightarrow$ （可选）轻量 DPO/KTO 迭代。

顺序理由：SFT 先提供可优化起点；偏好对齐在已有指令能力上修正；安全微调放后避免损害通用能力，且可覆盖越狱模式。

(2) QLoRA vs 全量 (3 分)

8×80GB 可全量 SFT 7B (权重 14GB + 优化器 $\approx 100\text{GB}$ + 分布式可承受)，但 DPO/RM 需同时加载 ref 模型，显存紧张。**推荐 QLoRA**：4-bit 基座 $\approx 3.5\text{GB/卡}$ + LoRA 梯度/优化器 $\ll$ 全量，8 卡 DP 可轻松跑 $r = 64$ ；主要显存项：量化权重 + LoRA 参数 + 激活 (与 L, B 相关) + 优化器 (仅 LoRA 部分)。

(3) 失败模式缓解 (3 分)

过度拒绝：加入「应正常回答」的 hard positive 样本做 SFT/DPO 平衡；副作用：可能降低安全阈值。**越狱**：加入对抗性 red-team 样本 + 安全 RM 约束或 Constitutional AI 自批判机制；副作用：训练成本上升，可能增加过度拒绝。